

3.36pt

# Teoria das Filas

André Rodrigues da Cruz

Centro Federal de Educação Tecnológica de Minas Gerais  
Departamento de Computação

Otimização II

# Teoria das Filas

- Estudo das **filas de espera**.
- *Exemplos*: Filas para compra, caixa eletrônico, máquinas para reparo, aviões decolarem (pousarem), veículos para serem descarregados, ...
- **Modelos de filas**: representação de *sistemas de filas*.
- Operação eficiente de filas.
- Fornecer capacidade de atendimento.
- Minimizar tempo de espera.
- Buscar equilíbrio entre custo de serviço e tempo de espera.

# Exemplo Protótipo

Um pronto de socorro de um hospital atende emergências. A qualquer momento há um médico de plantão. O hospital possui um aumento anual contínuo no número de atendimentos no pronto de socorro. É comum pacientes chegarem no horário de pico (início da noite) e ter de esperar atendimento médico.


Por esta razão, foi elaborada uma proposta de alocar um segundo médico para o pronto de socorro no horário de pico. Assim, duas emergências poderiam ser atendidas ao mesmo tempo.

O administrador do hospital foi designado para estudar esta questão.

# Estrutura Básica dos Modelos de Fila

- Processo de filas básico:

- 1 Clientes são gerados por uma *fonte de entrada*.
- 2 Clientes entram no *sistema de filas* (pega a fila).
- 3 Em certos momentos, um cliente é selecionado para atendimento.
  - Uma regra (*disciplina da fila*) conhecida é utilizada.
- 4 Atendimento do cliente realizado por um *mecanismo de atendimento*.
- 5 Cliente deixa a fila.



# Fonte de Entrada

- **População solicitante.**
- Tamanho finito ou infinito.
- Fonte de entrada limitada ou ilimitada.
- Quando população é muito grande e finito, considera-se infinito.
  - Hipótese implícita, caso não afirme o contrário.
- Geração de clientes ao longo do tempo:
  - Padrão estatístico deve ser informado.
  - Número de clientes até dado momento:
    - Hipótese comum: *processo de Poisson*.
  - **Tempo entre chegadas** consecutivas:
    - Hipótese comum: *distribuição exponencial*.
- Especificação de hipóteses incomuns. *Exemplo*: recusa.

# Fila

- Local onde clientes aguardam atendimento.
- Número máximo de clientes permitidos.
- Filas finitas ou infinitas.
- Filas finitas muito grandes: consideradas infinitas.
  - Facilidade dos cálculos.
  - Comportamento parecido.

# Disciplina da Fila

- Ordem de seleção dos integrantes da fila para atendimento.
- *Exemplos:*
  - Primeiro a chegar, primeiro atendido.
  - Aleatório.
  - Com prioridade.
  - ...

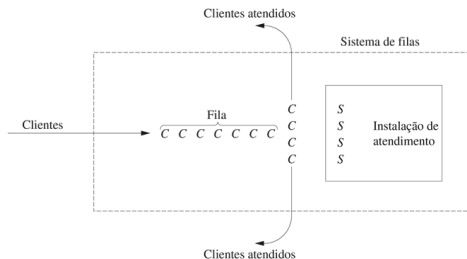


# Mecanismo de Atendimento

- Conjunto de *instalações de atendimento*.
- Canais de atendimento paralelos: **atendentes**.
- Em uma instalação:
  - Clientes podem ser atendidos em série.
- Mais de uma instalação de atendimento:
  - Cliente em algum canal de atendimento paralelo.
  - Cliente é totalmente atendido por um atendente.
- Modelo de fila específica:
  - Disposição das instalações.
  - Números de atendentes (canais paralelos) de cada instalação.
- Comumente se tem uma instalação com um ou mais atendentes.
- **Tempo de atendimento** (tempo de permanência):
  - Possui distribuição probabilística para cada atendente.
  - Comum supor mesma distribuição para todos atendentes.
  - Distribuições comuns: exponencial, constante e Erlang (Gamma).

# Processo de Fila Elementar

- Uma fila de espera única.
- Possui um ou mais atendentes.
- Cada cliente gerado por uma fonte de entradas.
- Cada cliente atendido por um atendente.
- Cliente aguarda um tempo para ser atendido.



- O exemplo do hospital é uma fila elementar.

# Processo de Fila Elementar

## Observações:

- *Um atendente não precisa ser um indivíduo.*  
Pode ser uma equipe, uma máquina, um veículo, um dispositivo eletrônico, ...
- *Os clientes não precisam ser pessoas.*  
Podem ser peças que aguardam uma operação, carros que aguardam no pedágio, ...
- *Não é necessário uma fila física.*  
A fila pode ser formada por máquinas em diferentes áreas aguardando reparo, jogadores online aguardando a vez de jogar, ...

# Processo de Fila Elementar

## Observações:

- É fornecido número médio que aguardam, tempo de espera médio, ...
- Tempos entre **chegadas** e de **atendimentos** são independentes e distribuídos de forma idêntica.
- Identificação convencional:  $\mathcal{A}/\mathcal{B}/\mathcal{C}$ 
  - 1  $\mathcal{A}$ : Distribuição de tempos entre atendimentos.
  - 2  $\mathcal{B}$ : Distribuição de tempos de atendimentos.
  - 3  $\mathcal{C}$ : Número de atendentes.
- Distribuições comuns:
  - $M$  = distribuição exponencial (markoviana).
  - $D$  = distribuição degenerada (tempos constantes).
  - $E_k$  = distribuição de Erlang (parâmetro de forma  $k$ ).
  - $G$  = distribuição geral (qualquer distribuição arbitrária).
- *Exemplo:*  $M/M/s$ , tempos entre atendimento e de atendimento com distribuição exponencial com  $s$  atendentes.

# Terminologia e Notação

- **Estado do sistema:** número de clientes no sistema de filas.
- **Comprimento da fila:** número de clientes que aguardam atendimento.
  - Estado menos o número de clientes em atendimento.
- $N(t)$ : número de clientes no sistema de fila no instante  $t \geq 0$ .
- $P_n(t)$  : probabilidade de exatamente  $n$  clientes no sistema de filas no instante  $t$ , dado o número no instante 0.
- $s$ : número de atendentes no sistema de fila.
- $\lambda_n$ : taxa média de chegada de novos clientes quando  $n$  clientes se encontram no sistema.
- $\mu_n$ : taxa média de atendimento para o sistema global quando  $n$  clientes se encontram no sistema.

# Terminologia e Notação

- Quando  $\lambda_n$  constante para todo  $n$ , representa-se por  $\lambda$ .
- Quando taxa média de atendimento por atendente ocupado é constante para todo  $n \geq 1$ , tem-se  $\mu$ .
  - $\mu_n = s\mu$  quando  $n \geq s$ .
- $1/\lambda$ : tempo esperado entre atendimentos.
- $1/\mu$ : tempo de atendimento esperado.
- $\rho = \lambda/(s\mu)$ : fator de utilização (fração de tempo esperada em que cada atendente se encontra ocupado).

# Terminologia e Notação

Resultados de estado estável:

- **Condição transiente:** logo após o sistema iniciar operação, o estado do sistema é afetado pelo estado inicial e pelo tempo decorrido.
- **Condição de estado estável:** após tempo suficiente, o sistema se torna independente do estado inicial e do tempo decorrido.
  - $P_n$  = probabilidade de  $n$  clientes se encontrarem no sistema de filas.
  - $L$  = número de clientes esperado no sistema de fila =  $\sum_{n=0}^{\infty} nP_n$ .
  - $L_q$  = comprimento esperado da fila =  $\sum_{n=s}^{\infty} (n - s)P_n$ .
  - $\mathcal{W}$  = tempo de espera no sistema para cada cliente<sup>1</sup>.
  - $W = E(\mathcal{W})$ .
  - $\mathcal{W}_q$  = tempo de espera na fila para cada cliente<sup>2</sup>.
  - $W_q = E(\mathcal{W}_q)$ .

---

<sup>1</sup>Inclui atendimento.

<sup>2</sup>Exclui atendimento.

# Relações entre $L$ , $W$ , $L_q$ e $W_q$

Suponha  $\lambda_n = \lambda$  constante para todo  $n$ . Em um processo de fila com estado estável:

- $L = \lambda W$ .
- $L_q = \lambda W_q$
- Se  $\lambda_n$  não constante, substituir  $\lambda$  por  $w\bar{\lambda}$  (taxa média de chegada a longo prazo).

Suponha que o tempo médio de atendimento,  $1/\mu$ , constante para todo  $n \geq 1$ :

- $W = W_q + \frac{1}{\mu}$



# Distribuição Exponencial

- Suponha  $T$  variável aleatória que represente tempos entre chegadas ou tempos de atendimentos.
- Distribuição exponencial com parâmetro  $\alpha$ :

$$f_T(t) = \begin{cases} \alpha e^{-\alpha t} & \text{para } t \geq 0 \\ 0 & \text{para } t < 0 \end{cases}$$

- Probabilidade cumulativas (dado  $t \geq 0$ ):

$$\begin{aligned} P(T \leq t) &= 1 - e^{-\alpha t} \\ P(T > t) &= e^{-\alpha t} \end{aligned}$$


- Valor esperado e variância:

$$\begin{aligned} E(T) &= 1/\alpha \\ \text{var}(T) &= 1/\alpha^2 \end{aligned}$$

# Distribuição Exponencial

**Propriedade 1:**  $f_T(t)$  é decrescente para  $t \geq 0$ .

- $P(0 \leq T \leq \Delta t) > P(t \leq T \leq t + \Delta t)$  para quaisquer  $t > 0$  e  $\Delta t > 0$ .
- $T$  assume valor mais próximo de zero.
- Tempos próximos da média.
- Tempos de/entre atendimentos normalmente são breves.
- Tempos prolongados são mais raros.
- *Exemplos:* pronto socorro, caixa de supermercado, caixa eletrônico.



# Distribuição Exponencial

## Propriedade 2: Ausência de memória.

- $P(T > t + \Delta t \mid T > \Delta t) = P(T > t)$  para quaisquer  $t > 0$  e  $\Delta t > 0$ :

$$\begin{aligned}
 P(T > t + \Delta t \mid T > \Delta t) &= \frac{P(T > \Delta t, T > t + \Delta t)}{P(T > \Delta t)} \\
 &= \frac{P(T > t + \Delta t)}{P(T > \Delta t)} \\
 &= \frac{e^{-\alpha(t+\Delta t)}}{e^{-\alpha\Delta t}} \\
 &= e^{-\alpha t} \\
 &= P(T > t).
 \end{aligned}$$

- *Tempos entre atendimentos*: tempo até a próxima chegada não sofre influência de quando ocorreu última chegada.
- *Tempos de atendimentos*: situação na qual operações de atendimento diferem.

# Distribuição Exponencial

**Propriedade 3:** O mínimo de diversas variáveis aleatórias segue distribuição exponencial.

- Sejam  $T_1, T_2, \dots, T_n$  variáveis aleatórias exponenciais independentes com parâmetros  $\alpha_1, \alpha_2, \dots, \alpha_n$ .
- Façamos  $U = \min(T_1, T_2, \dots, T_n)$ , o mínimo dos valores assumidos por  $T_1, T_2, \dots, T_n$ .
- Se  $T_i$  representa o tempo até que certo evento ocorra, então  $U$  representa o tempo até que o primeiro dos  $n$  eventos ocorra. Para  $t \geq 0$ :

$$\begin{aligned}
 P(U > t) &= P(T_1 > t, T_2 > t, \dots, T_n > t) \\
 &= P(T_1 > t)P(T_2 > t) \dots P(T_n > t) \\
 &= e^{-\alpha_1 t} e^{-\alpha_2 t} \dots e^{-\alpha_n t} \\
 &= \exp\left(-\sum_{i=1}^n \alpha_i t\right)
 \end{aligned}$$

- $U$  possui distribuição exponencial com parâmetro  $\alpha = \sum_{i=1}^n \alpha_i$ .

# Distribuição Exponencial

**Propriedade 3:** O mínimo de diversas variáveis aleatórias segue distribuição exponencial.

- Implicação para **tempos entre atendimento**: Suponha  $n$  tipos de clientes distintos, com tempos entre atendimento exponenciais  $T_i$  de parâmetros  $\alpha_i$  para cada tipo de cliente  $i \in \{1, \dots, n\}$ .  $U$  é o tempo entre atendimento do sistema, como um todo, com parâmetro  $\alpha = \sum_{i=1}^n \alpha_i$ .
- Ignora-se a distinção de clientes.

# Distribuição Exponencial

**Propriedade 3:** O mínimo de diversas variáveis aleatórias segue distribuição exponencial.

- Implicação para **tempos de atendimento**: Suponha  $n$  atendentes com tempos de atendimentos  $T_i$  exponenciais com parâmetro  $\alpha_i = \mu$ ,  $i \in \{1, \dots, n\}$ .  $U$  é o tempo de atendimento do sistema, como um todo, com parâmetro  $\alpha = n\mu$ .
- Mesmo comportamento de uma fila com um atendente com parâmetro  $n\mu$ .
- Probabilidade do atendente  $j \in \{1, \dots, n\}$  terminar um atendimento primeiro, entre os  $n$  atendentes:

$$P(T_j = U) = \frac{\alpha_j}{\sum_{i=1}^n \alpha_i}$$

# Distribuição Exponencial

## Propriedade 4: Relação com a distribuição de Poisson.

- Suponha que o tempo entre um evento consecutivo siga distribuição exponencial com parâmetro  $\alpha$ .
- Determinação da probabilidade do número de vezes que esse evento ocorreu ao longo do tempo.
- Seja  $X(t)$  o número de ocorrências no tempo  $t \geq 0$ . Para  $n = 0, 1, \dots$ , tem-se que:

$$P(X(t) = n) = \frac{(\alpha t)^n e^{-\alpha t}}{n!}$$

- $X(t)$  segue distribuição de Poisson com parâmetro  $\alpha t$ .
- Para  $n = 0$ ,  $P(X(t) = 0) = e^{-\alpha t}$ , probabilidade da distribuição exponencial para o primeiro evento após o tempo  $t$ .

# Distribuição Exponencial

**Propriedade 4:** Relação com a distribuição de Poisson.

- Média:  $E(X(t)) = \alpha t$ .
- $\alpha$  é a taxa média de ocorrência do evento.
- **Número de termos de atendimento:**
  - Tempos de atendimento com distribuição exponencial com  $\alpha = \mu$ .
  - $X(t)$ : número de atendimentos realizados por um atendente até  $t$ .
  - Para modelos com  $n$  atendentes,  $\alpha = n\mu$ .
  - *Processo de Poisson* com taxa  $\alpha$ : eventos contados de forma contínua.
- **Número de chegadas:**
  - Tempos entre atendimentos com distribuição exponencial com  $\alpha = \lambda$ .
  - $X(t)$ : número de chegadas no tempo decorrido  $t$ .
  - *Processo de Poisson* com parâmetro  $\lambda$  (taxa de chegada).
  - *Entrada de Poisson*.
  - Todo período de duração fixa tem a mesma chance de ter uma chegada independentemente de quando ocorreu a última chegada.



# Distribuição Exponencial

**Propriedade 5:** Para  $t > 0$ ,  $P(T \leq t + \Delta t | T > \Delta t) \approx \alpha \Delta t$ , para  $\Delta t$  pequeno.

- É sabido que  $e^x = 1 + x + \sum_{n=2}^{\infty} \frac{x^n}{n!}$ .
- Para um valor pequeno  $\Delta t > 0$ :

$$\begin{aligned}
 P(T \leq t + \Delta t | T > t) &= P(T \leq \Delta t) \\
 &= 1 - e^{-\alpha \Delta t} \\
 &= 1 - 1 + \alpha \Delta t - \sum_{n=2}^{\infty} \frac{(-\alpha \Delta t)^n}{n!}
 \end{aligned}$$

- Com  $\alpha \Delta t \approx 0$ , os termos do somatório se tornam relativamente desprezíveis.

# Distribuição Exponencial

## Propriedade 6: Não se afeta por agregação ou desagregação


- Agregação:
  - Suponha  $n$  tipos distintos de clientes que chegam em processos independentes de Poisson com parâmetro  $\lambda_i$ ,  $i \in \{1, 2, \dots, n\}$ .
  - Processo de entrada agregado é um processo de Poisson com parâmetro (taxa média de chegada)  $\lambda = \lambda_1 + \lambda_2 + \dots + \lambda_n$ .
- Desagregação:
  - Seja um processo de Poisson agregado com parâmetro  $\lambda$  e  $n$  tipos distintos de clientes, com probabilidade fixa de chegada  $p_i$ , para  $i \in \{1, 2, \dots, n\}$  e  $\sum_{i=1}^n p_i = 1$ .
  - A taxa de chegada de cada cliente será  $\lambda_i = p_i \lambda$ .
- *Exemplo:* Dois tipos de clientes chegam em uma fila em um processo de Poisson com parâmetro  $\lambda$ . Cada cliente tem probabilidade fixa  $p$  de recusar a entrar na fila. E  $1 - p$  de entrar na fila. Cada tipo de cliente chega em um processo de Poisson com parâmetros  $p\lambda$  e  $(1 - p)\lambda$ . O desempenho da fila pode ser analisado através do parâmetro  $(1 - p)\lambda$ .

# Processo de Nascimento e Morte

- Nascimento (novo cliente) e Morte (cliente atendido).
- Estado é o número de clientes  $N(t)$  no tempo  $t \geq 0$ .
- Descrição probabilística de  $N(t)$ .
- Nascimentos e mortes individuais ocorrem aleatoriamente, cujas taxas dependem apenas do estado atual do sistema.
- Hipóteses:
  - 1 Dado  $N(t) = n$ , ( $n = 0, 1, 2, \dots$ ), segue a distribuição exponencial com parâmetro:
    - $\lambda$ , a variável tempo remanescente até a próxima chegada.
    - $\mu$ , a variável tempo remanescente até a próxima saída.
  - 2 As variáveis aleatórias para o tempo até a próxima chegada e para o tempo até a próxima saída são independentes. A transição ocorre por unidades ( $n \rightarrow n + 1$  ou  $n \rightarrow n - 1$ ).

# Análise do Processo de Nascimento e Morte

- Cadeia de Markov em tempo contínuo:



- $\lambda_n$ : taxa média de chegada estando o sistema no estado  $n$ .
- $\mu_n$ : taxa média de saída estando o sistema no estado  $n$ .
- $P_n$ : proporção de tempo que sistema fica no estado  $n$ .
- Condição de estado estável: taxa que entra igual a taxa que sai.
- Equação de equilíbrio par o estado  $n$ .
  - Para o estado 0:  $\mu_1 P_1 = \lambda_0 P_0$ .
  - Para o estado 1:  $\mu_1 P_1 + \lambda_1 P_1 = \lambda_0 P_0 + \mu_2 P_2$ .
  - Para o estado 2:  $\mu_2 P_2 + \lambda_2 P_2 = \lambda_1 P_1 + \mu_3 P_3$ .
  - ...
  - Ao final  $\sum_{i=0}^{\infty} P_i = 1$ .

# Análise do Processo de Nascimento e Morte

Estado:

$$0 : P_1 = \frac{\lambda_0}{\mu_1} P_0$$

$$1 : P_2 = \frac{\lambda_1}{\mu_2} P_1 + \frac{1}{\mu_2} (\mu_1 P_1 - \lambda_0 P_0) = \frac{\lambda_1}{\mu_2} P_1 = \frac{\lambda_1 \lambda_0}{\mu_2 \mu_1} P_0$$

$$2 : P_3 = \frac{\lambda_2}{\mu_3} P_2 + \frac{1}{\mu_3} (\mu_2 P_2 - \lambda_1 P_1) = \frac{\lambda_2}{\mu_3} P_2 = \frac{\lambda_2 \lambda_1 \lambda_0}{\mu_3 \mu_2 \mu_1} P_0$$

$\vdots$

De maneira geral, para  $n \in \{0, 1, 2, \dots\}$ , tem-se que:

- $$C_n = \frac{\lambda_{n-1} \lambda_{n-2} \dots \lambda_0}{\mu_n \mu_{n-1} \dots \mu_1} \text{ para } n > 0 \text{ e } C_0 = 1$$

- $$P_n = C_n P_0$$

# Análise do Processo de Nascimento e Morte

- $\sum_{n=0}^{\infty} P_n = 1$  implica  $(\sum_{n=0}^{\infty} C_n) P_0 = 1$  e  $P_0 = (\sum_{n=0}^{\infty} C_n)^{-1}$ .
- Para filas que se baseiam no processo de nascimento e morte:
  - $L = \sum_{n=0}^{\infty} n P_n$
  - $L_q = \sum_{n=s}^{\infty} (n - s) P_n$
  - $W = L / \bar{\lambda}$
  - $W_q = L_q / \bar{\lambda}$
  - $\bar{\lambda} = \sum_{n=0}^{\infty} \lambda_n P_n$  (taxa média de chegada a longo prazo)

# Análise do Processo de Nascimento e Morte

- Somatórios possuem solução analítica em casos especiais:
  - $\sum_{n=0}^N x^n = (1 - x^{N+1})/(1 - x)$ .
  - $\sum_{n=0}^{\infty} x^n = 1/(1 - x)$ , para  $|x| < 1$ .
- Resultados válidos sob hipótese de que parâmetros  $\lambda_n$  e  $\mu_n$  alcancem condição de estado estável.
- Hipótese sempre válida quando:
  - $\lambda_n = 0$  para  $n > 0$  (número finito de estados).
  - $\lambda$  e  $\mu$  são definidos de forma que  $\rho = \lambda/(s\mu) < 1$ .
- Hipótese não válida quando  $\sum_{n=0}^{\infty} C_n = \infty$ .

# Modelo M/M/s

- Tempos entre atendimentos e Tempos de atendimento são distribuídos de forma independente e idêntica de acordo com a distribuição exponencial.
- Número de atendentes é o inteiro positivo  $s$ .
- Caso especial do processo de nascimento e morte.
- Taxa **média** de chegada ( $\lambda$ ) e de atendimento por atendente ocupado ( $\mu$ ) são constantes.



# Modelo M/M/s

- Quando  $s = 1$  (único atendente):
  - $\lambda_n = \lambda, n = 0, 1, 2, \dots$
  - $\mu_n = \mu, n = 1, 2, 3, \dots$
- Quando  $s > 1$  (vários atendentes):
  - $\mu_n = \begin{cases} n\mu & \text{quando } n \leq s. \\ s\mu & \text{quando } n > s. \end{cases}$
  - Quando  $s\mu$  excede  $\lambda$ , tem-se


$$\rho = \frac{\lambda}{s\mu} < 1$$

- Nesta condição atinge-se estado estável.

# Modelo M/M/s


(a) Um único atendente ( $s = 1$ )

$$\begin{aligned}\lambda_n &= \lambda, & \text{para } n = 0, 1, 2, \dots \\ \mu_n &= \mu, & \text{para } n = 1, 2, \dots\end{aligned}$$



(b) Diversos atendentes ( $s > 1$ )

$$\begin{aligned}\lambda_n &= \lambda, & \text{para } n = 0, 1, 2, \dots \\ \mu_n &= \begin{cases} n\mu, & \text{para } n = 1, 2, \dots, s \\ s\mu, & \text{para } n = s, s+1, \dots \end{cases}\end{aligned}$$



Diagramas de taxas para o modelo M/M/s.

# Resultados para M/M/1

- $P_0 = \left( \sum_{n=0}^{\infty} \rho^n \right)^{-1} = \left( \frac{1}{1-\rho} \right)^{-1} = 1 - \rho$
- $C_n = \left( \frac{\lambda}{\mu} \right)^n = \rho^n$  para  $n = 0, 1, 2, \dots$
- $P_n = \rho^n P_0 = (1 - \rho) \rho^n$  para  $n = 0, 1, 2, \dots$
- $L = \sum_{n=0}^{\infty} n(1 - \rho) \rho^n = \dots = \frac{\rho}{1 - \rho} = \frac{\lambda}{\mu - \lambda}$
- $L_q = \sum_{n=1}^{\infty} (n - 1) P_n = L - 1(1 - P_0) = \frac{\lambda^2}{\mu(\mu - \lambda)}$

# Resultados para M/M/1

- Quando  $\lambda \geq \mu$  fila cresce sem limites a longo prazo.
- Supondo  $\lambda < \mu$ , deriva-se distribuição de probabilidades do tempo de espera total no sistema,  $\mathcal{W}$ .
- Atendimentos em ordem de chegada.
- Se na chegada encontra-se  $n$  clientes, deve-se contabilizar  $n + 1$  tempos de atendimento  $T_1, T_2, \dots, T_n, T_{n+1}$  que são variáveis aleatórias que seguem distribuição exponencial, com parâmetro  $\mu$ .
- Seja  $S_{n+1}$  o tempo de espera condicional dado  $n$  clientes no sistema:

$$S_{n+1} = T_1 + T_2 + \dots + T_n + T_{n+1}, \quad \text{para } n = 0, 1, 2, \dots$$

- $S_{n+1}$  segue distribuição de Erlang (gama).

# Resultados para M/M/1

- $P(W > t) = \sum_{n=0}^{\infty} P_n P(S_{n+1} > t) = e^{-\mu(1-\rho)t}$  para  $t \geq 0$ .
- $W$  segue distribuição exponencial com parâmetro  $\mu(1 - \rho)$ .
- $W = E(W) = \frac{1}{\mu(1 - \rho)} = \frac{1}{(\mu - \lambda)}$ .
- $P(W_q = 0) = P_0 = 1 - \rho$ , com nenhum cliente no sistema.
- $P(W_q > t) = \sum_{n=1}^{\infty} P_n P(S_n > t) = \dots = \rho e^{-\mu(1-\rho)t}$  para  $t \geq 0$ .
- $W_q = E(W_q) = \frac{\lambda}{\mu(\mu - \lambda)}$ .

# Resultados para M/M/s com $s > 1$

- $P_0 = 1 / \left( \sum_{n=0}^{s-1} \frac{(\lambda/\mu)^n}{n!} + \frac{(\lambda/\mu)^s}{s!} \frac{1}{1 - \lambda/(s\mu)} \right)$
- $C_n = \begin{cases} \frac{(\lambda/\mu)^n}{n!} & \text{para } n = 1, 2, \dots, s \\ \frac{(\lambda/\mu)^n}{s! s^{n-s}} & \text{para } n = s, s+1, \dots \end{cases}$
- $P_n = \begin{cases} \frac{(\lambda/\mu)^n}{n!} P_0 & \text{para } 0 \leq n \leq s \\ \frac{(\lambda/\mu)^n}{s! s^{n-s}} P_0 & \text{para } n \geq s \end{cases}$
- $L_q = \sum_{n=s}^{\infty} (n-s) P_n = \dots = \frac{P_0 (\lambda/\mu)^s \rho}{s! (1-\rho)^2}$
- $W_q = \frac{L_q}{\lambda}$
- $W = W_q + \frac{1}{\mu}$
- $L = \lambda \left( W_q + \frac{1}{\mu} \right) = L_q + \frac{\lambda}{\mu}$

# Resultados para M/M/s com $s > 1$

- Quando  $\lambda \geq s\mu$  fila cresce indefinitivamente a longo prazo.
- Resultados não se aplicam.
- Supondo  $\lambda < s\mu$ , para  $t \geq 0$ :

- $$P(\mathcal{W} > t) = e^{-\mu t} \left[ 1 + \frac{P_0(\lambda/\mu)^s}{s!(1-\rho)} \left( \frac{1 - e^{-\mu(s-1-\lambda/\mu)t}}{s-1-\lambda/\mu} \right) \right].$$
- $$P(\mathcal{W}_q = 0) = \sum_{n=0}^{s-1} P_n.$$
- $$P(\mathcal{W}_q > t) = (1 - P(\mathcal{W}_q = 0))e^{-s\mu(1-\rho)t}.$$

## Exemplo do Hospital

O administrador do hospital verificou que a chegada de atendimentos e tempo o gasto para atendê-los seguem distribuições exponenciais. Assim, ele optou por uma modelagem  $M/M/s$ .

Inicialmente, ele estimou que os pacientes chegam em uma taxa média de 1 a cada  $1/2$  hora e que um médico precisa em média de 20 minutos para atender cada paciente. Portanto, utilizando uma hora como unidade de tempo, tem-se:

- $1/\lambda = 1/2$  hora por cliente ( $\lambda = 2$  clientes por hora).
- $1/\mu = 1/3$  hora por cliente ( $\mu = 3$  clientes por hora).



## Exemplo do Hospital

São considerados ter um ( $s = 1$ ) ou dois médicos ( $s = 2$ ). Assim:

	$s = 1$	$s = 2$
$\rho$	$2/3$	$1/3$
$P_0$	$1/3$	$1/2$
$P_1$	$2/9$	$1/3$
$P_n, n \geq 2$	$\frac{1}{3} \left(\frac{2}{3}\right)^n$	$\left(\frac{1}{3}\right)^n$
$L_q$	$4/3$	$1/12$
$L$	$2$	$3/4$
$W_q$	$2/3$ hora	$1/24$ hora
$W$	$1$ hora	$3/8$ hora
$P(\mathcal{W}_q > 0)$	$0,667$	$0,167$
$P(\mathcal{W}_q > 1/2)$	$0,404$	$0,022$
$P(\mathcal{W}_q > 1)$	$0,245$	$0,003$
$P(\mathcal{W}_q > t)$	$(2/3)e^{-t}$	$(1/6)e^{-4t}$
$P(\mathcal{W} > t)$	$e^{-t}$	$(1/2)e^{-3t}(3 - e^{-t})$

Um único médico seria inadequado!